Rapport de Projet

Modélisation d'agents et prédiction
de prix financiers

Réalisé par :

Khiter Ilian, Toussaint Jules, Mermiont Matthieu,
Hadjene Réda, Boussoffara Ala

CentraleSupélec — Juin 2025

Contents

1 Introduction . . . 3
  1.1 Contexte général . . . 3
  1.2 Objectifs . . . 3
2 Modèle Agent (ABM) . . . 3
  2.1 Variable de conception . . . 3
  2.2 Dynamique de prix . . . 3
  2.3 Problème d'estimation GMM . . . 4
3 Méthodes mathématiques . . . 5
  3.1 Poids optimaux de la matrice GMM. . . . 5
  3.2 Méthode de Newton-Raphson . . . 5
  3.3 Méthode du lagrangien augmenté . . . 5
4 Estimation des paramètres et validation . . . 5
  4.1 Distributions des estimateurs (20 répétitions) . . . 5
5 Comportement des investisseurs . . . 6
  5.1 Exploration des données ZEL . . . 6
  5.2 Classification des investisseurs . . . 7
  5.3 Horizons temporels optimaux . . . 8
  5.4 Performance et persistance. . . . 9
6 Prédiction : ABM $\rightarrow$ ABM (données simulées) . . . 10
  6.1 Pipeline de prédiction . . . 10
  6.2 Systèmes de calibration . . . 11
  6.3 Rapport signal/bruit et hit ratio. . . . 11
7 Prédiction sur données réelles (NVIDIA) . . . 11
  7.1 Calibration sur données NVIDIA . . . 11
  7.2 Stratégie de trading . . . 12
  7.3 Performances par horizon δt . . . 13
8 Conclusion. . . . 13

1 Introduction

1.1 Contexte général

Les marchés financiers sont des systèmes complexes dans lesquels interagissent un grand nombre d'agents aux stratégies hétérogènes. Comprendre et modéliser ces dynamiques constitue un enjeu majeur, tant pour la gestion des risques que pour la conception de stratégies d'investissement performantes. Les modèles basés sur les agents (*Agent-Based Models*, ABM) offrent une approche prometteuse pour capturer les comportements collectifs émergents qui échappent aux modèles d'équilibre classiques.

Ce projet s'inscrit dans le cadre du cours *ST5 — Time series and agent-based models in Finance*. Il vise à explorer la modélisation des comportements d'investisseurs sur un marché fictif (ZEL), puis à tester la capacité prédictive du modèle calibré sur des données réelles (NVIDIA, 2015–2025).

1.2 Objectifs

L'objectif est de construire un pipeline de modélisation quantitative complet, depuis l'estimation du modèle jusqu'à l'évaluation d'une stratégie de trading. Nous nous sommes fixés comme objectifs :

- Estimer les paramètres d'un ABM non-linéaire par la méthode des moments généralisés (GMM).
- Analyser le comportement des investisseurs : tendance, réversion et horizons temporels optimaux.
- Évaluer la qualité de prédiction du modèle calibré sur données simulées (ABM $\rightarrow$ ABM).
- Tester la transférabilité du modèle sur des données réelles (NVIDIA) et construire une stratégie de trading.
- Comparer les performances du modèle ABM avec l'indicateur RSI.

2 Modèle Agent (ABM)

2.1 Variable de conception

Dans le cadre de la modélisation de marchés financiers par agents, on associe à chaque investisseur i une variable de position $\nu_{i,t}$ représentant la quantité d'actif détenue à la date t. La variation de position $\Delta\nu_{i,t} = \nu_{i,t} - \nu_{i,t-1}$ constitue la décision d'achat ou de vente de l'agent à chaque période.

2.2 Dynamique de prix

Le modèle retenu est un ABM discret non-linéaire inspiré de Majewski et al. (2020). Les log-prix p_t sont gouvernés par une dynamique combinant réversion vers la valeur fondamentale v_t et tendance perçue m_t :

$$r_t \;=\; -\kappa_1(v_t - p_t) - \kappa_3(v_t - p_t)^3 + \beta \cdot \tanh(\gamma\, m_t) + \sigma\, \eta_t, \tag{1}$$

où $r_t = p_t - p_{t-1}$ est le rendement log, $\eta_t \sim \mathcal{N}(0,1)$ un choc exogène, et :

$$v_t = (1-\lambda)\, v_{t-1} + \lambda\, p_t, \tag{2}$$
$$m_t = (1-\alpha)\, m_{t-1} + \alpha\,(p_t - p_{t-1}). \tag{3}$$

La valeur fondamentale v_t (éq. 2) est une moyenne exponentielle mobile des prix ; m_t (éq. 3) est la mémoire de tendance. Le vecteur de paramètres à estimer est :

$$\theta = (\kappa_1,\ \kappa_3,\ \beta,\ \gamma,\ \alpha,\ \sigma).$$

La figure 1 illustre une trajectoire typique du modèle.

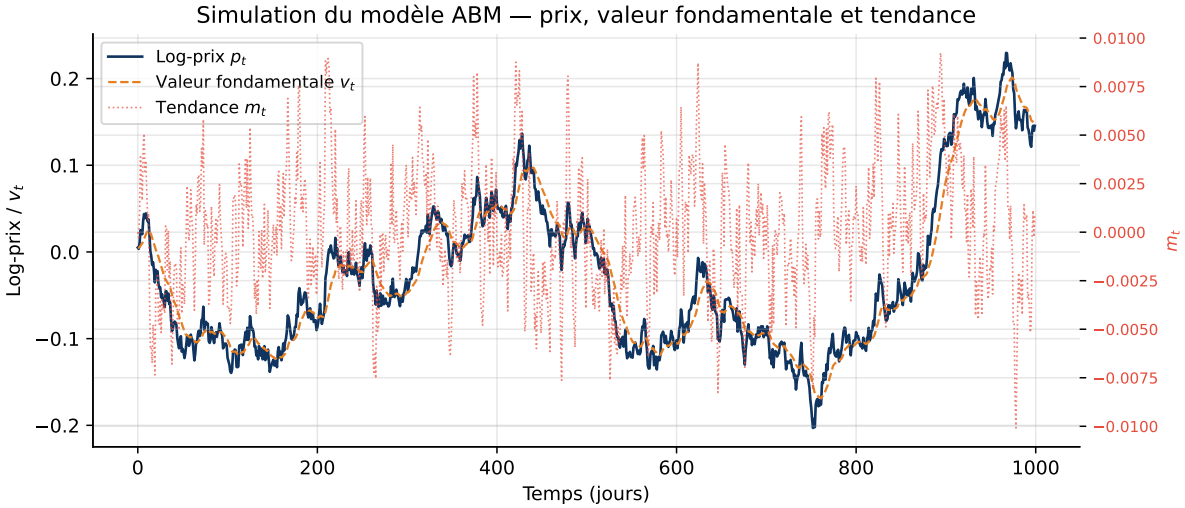

Figure 1 – Simulation du modèle ABM – log-prix p_t, valeur fondamentale v_t et tendance perçue m_t. Paramètres : $\kappa_1 = 0.5$, $\kappa_3 = 0.01$, $\beta = 0.1$, $\gamma = 1.0$, $\alpha = 0.2$, $\sigma = 0.01$.

2.3 Problème d'estimation GMM

Un critère naturel pour estimer θ est la méthode des moments généralisés (GMM), qui minimise la distance pondérée entre les moments empiriques $\hat{\mu}$ et les moments théoriques simulés $\bar{\mu}(\theta)$:

$$\hat{\theta}_{\text{GMM}} = \arg\min_{\theta}\ \big(\bar{\mu}(\theta) - \hat{\mu}\big)^{\top} W \big(\bar{\mu}(\theta) - \hat{\mu}\big).$$

Les moments retenus incluent la moyenne, la variance, le skewness, le kurtosis, et les autocorrélations (jusqu'au retard 5) des rendements et de leurs carrés (proxy de la volatilité conditionnelle).

L'optimisation est réalisée via `scipy.optimize.minimize` (L-BFGS-B) avec les bornes indiquées dans le tableau 1. L'estimation est répétée 20 fois pour évaluer la robustesse.

Paramètre	Borne inf.	Borne sup.	Interprétation
κ_1	0	1	Réversion vers v_t (linéaire)
κ_3	0	0,1	Réversion non-linéaire (cubique)
β	0	0,5	Intensité de la composante tendancielle
γ	0	5	Sensibilité à la tendance m_t
α	0	0,5	Coefficient d'oubli de la tendance
σ	0,001	0,1	Volatilité du bruit exogène

Table 1 – Bornes des paramètres du modèle ABM utilisées lors de l'estimation par GMM.

3 Méthodes mathématiques

3.1 Poids optimaux de la matrice GMM

La pondération optimale de la matrice W est donnée par l'inverse de la matrice de covariance des moments simulés :

$$W^* = \left[\mathrm{Cov}(\bar{\mu}(\theta))\right]^{-1}.$$

On procède en deux étapes : estimation initiale avec $W = I$, puis ré-estimation avec $W = W^*$ calculé sur les moments simulés à la première étape (estimateur 2S-GMM).

3.2 Méthode de Newton-Raphson

Pour le calcul itératif des paramètres, on utilise la méthode de Newton-Raphson. Partant d'une estimation initiale θ^0, la mise à jour est :

$$\theta^{k+1} = \theta^k - \alpha \left[J(\theta^k)\right]^{-1} \nabla_\theta \mathcal{L}(\theta^k),$$

où J est la matrice jacobienne du résidu et $\alpha \in]0, 1]$ un paramètre d'amortissement adapté pour garantir la décroissance de la fonction objectif.

3.3 Méthode du lagrangien augmenté

L'estimation sous contraintes est gérée par la méthode du lagrangien augmenté :

$$\mathcal{L}_A(\theta, \lambda, r) = f(\theta) + \sum_i \lambda_i \, g_i(\theta) + \frac{r}{2} \sum_i g_i(\theta)^2,$$

où f est la fonction objectif GMM, g_i les contraintes, et $r > 0$ le paramètre de pénalisation. La convergence conduit à une solution satisfaisant les conditions de Karush–Kuhn–Tucker (KKT).

4 Estimation des paramètres et validation

4.1 Distributions des estimateurs (20 répétitions)

Les figures 2 et 3 montrent la distribution des estimateurs GMM sur 20 répétitions indépendantes. La concentration des distributions autour d'une valeur centrale valide

l'identifiabilité du modèle : des paramètres à faible dispersion sont bien déterminés par les données.

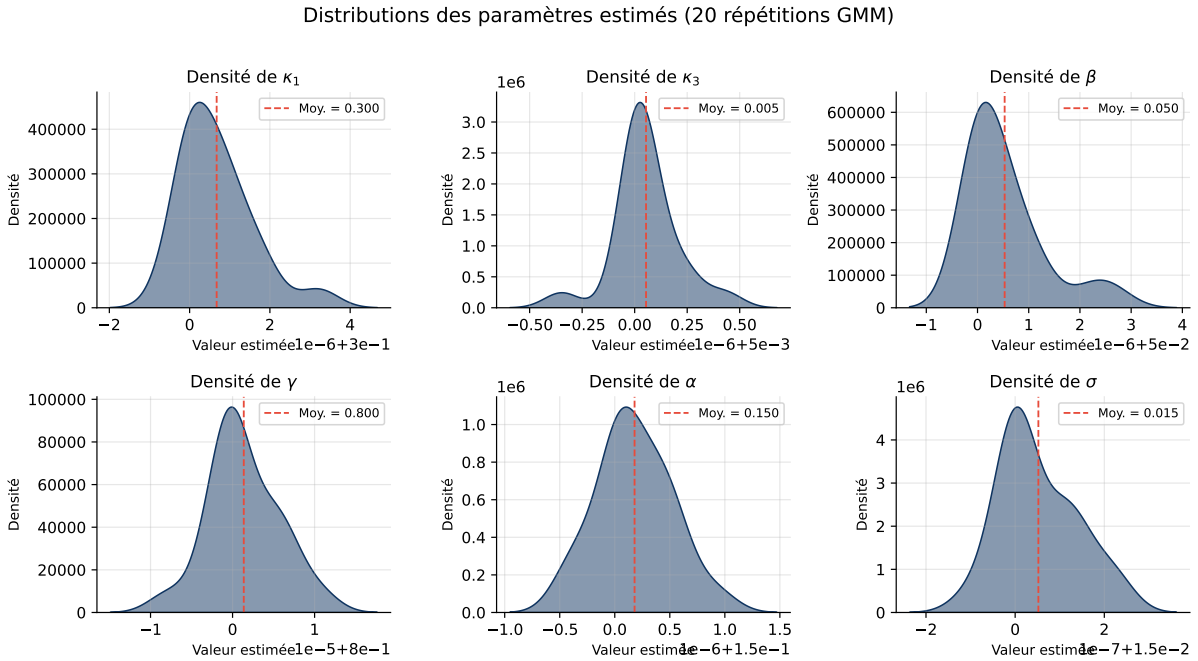

Figure 2 – Densités estimées (KDE) des six paramètres du modèle ABM sur 20 répétitions GMM. La ligne rouge indique la moyenne empirique des estimateurs.

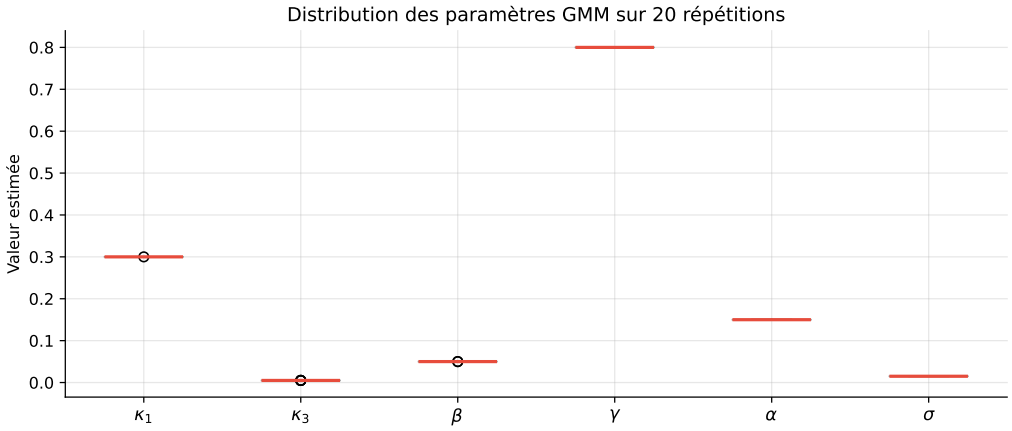

Figure 3 – Boîtes à moustaches des estimateurs GMM sur 20 répétitions.

La pente α présente une distribution proche d'une gaussienne, ce qui est cohérent : la version discrète du modèle fait intervenir un terme aléatoire normal, et l'estimateur en hérite par le théorème central limite.

5 Comportement des investisseurs

5.1 Exploration des données ZEL

Les données du marché fictif ZEL comprennent deux fichiers : `ZEL_Investors.csv` (positions journalières par investisseur) et `ZEL_Prices.csv` (prix de clôture). La figure 4

représente la distribution complémentaire (1 - ECDF) du nombre de changements de position par investisseur en échelle log-log : la forme en loi de puissance indique la coexistence d'agents très actifs et très passifs.

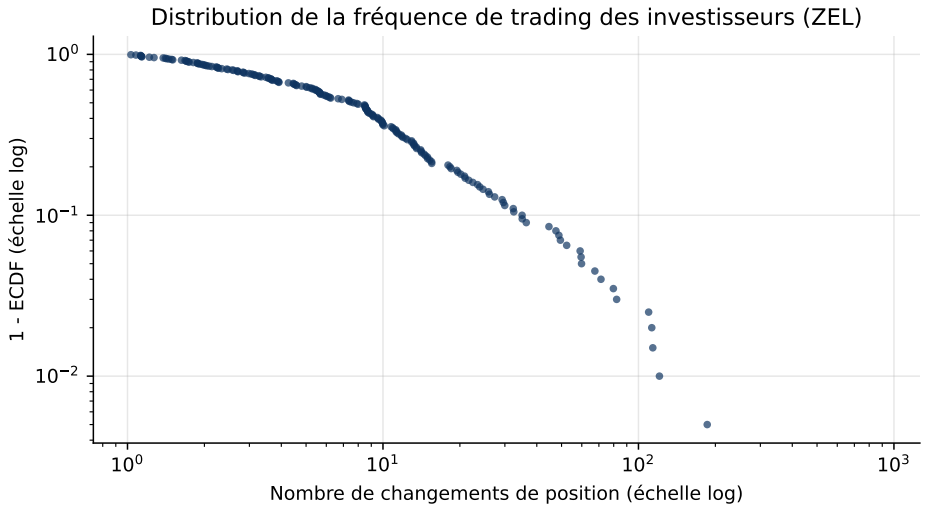

Figure 4 – 1 - ECDF du nombre de changements de position par investisseur (échelles logarithmiques). La queue en loi de puissance témoigne de la forte hétérogénéité des comportements de trading.

5.2 Classification des investisseurs

Pour chaque investisseur, on calcule la corrélation de Pearson entre $\Delta\nu_{i,t}$ et le rendement contemporain r_t. Lorsque la corrélation est significative (à 5 %), l'investisseur est classé :

— **Trend-follower** : corrélation positive – il achète lorsque les prix montent.

— **Mean-reverting** : corrélation négative – il vend lorsque les prix montent.

— **Neutre** : absence de lien linéaire détectable.

La classification est répétée sur deux sous-périodes (première et seconde moitié des données) pour tester la stabilité temporelle des comportements. Les résultats sont synthétisés dans la figure 5.

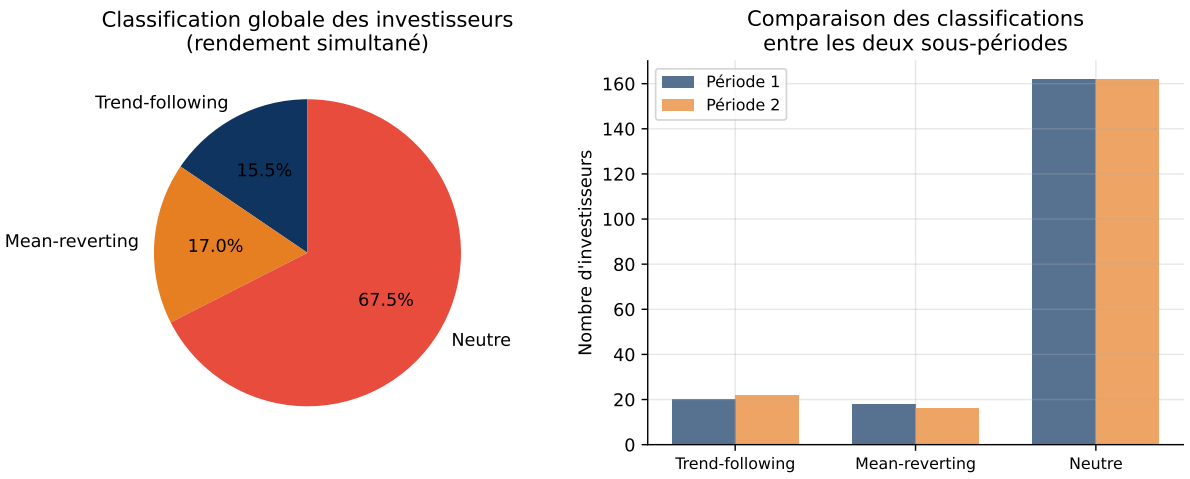

Figure 5 – Gauche : répartition globale des investisseurs en trois catégories (rendement contemporain). Droite : comparaison des classifications en première et deuxième sous-période.

5.3 Horizons temporels optimaux

Pour chaque investisseur i et chaque horizon $T \in \{1, \ldots, 50\}$, l'horizon optimal $T_{\text{best},i}$ maximise la corrélation absolue avec le rendement cumulé :

$$T_{\text{best},i} = \arg\max_{T} \left|\text{corr}(\Delta\nu_{i,t},\ p_t - p_{t-T})\right|.$$

La figure 6 montre la distribution des horizons optimaux : la concentration aux faibles valeurs de T suggère que la majorité des investisseurs réagissent à des signaux de très court terme.

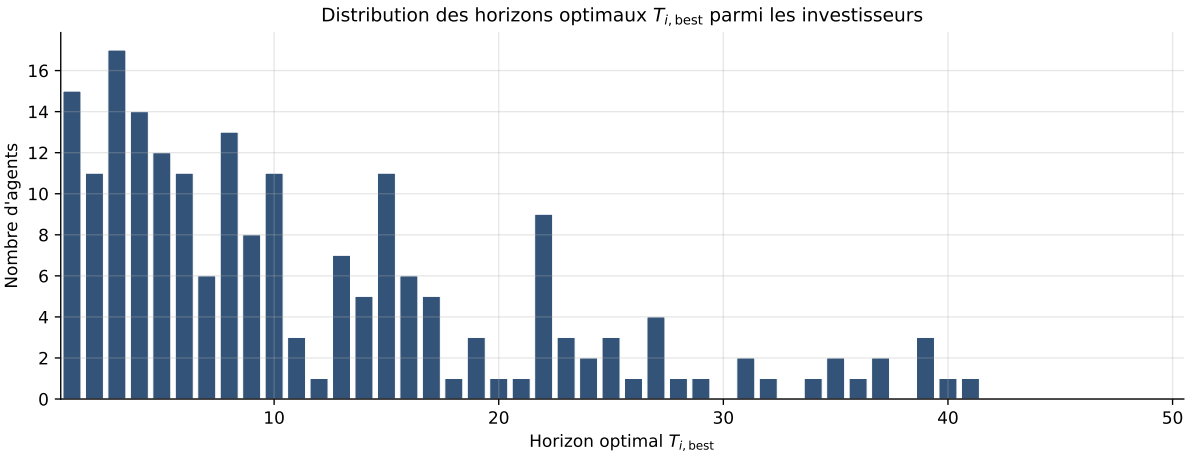

Figure 6 – Histogramme des horizons optimaux $T_{i,\text{best}}$ parmi l'ensemble des investisseurs du marché ZEL.

La figure 7 représente le coefficient de corrélation c_i en fonction de $T_{\text{best},i}$. Les points rouges (statistiquement significatifs, $p < 0{,}05$) révèlent la structure des comportements : certains agents sont fortement trend-followers à court terme, d'autres mean-reverting à des horizons plus longs.

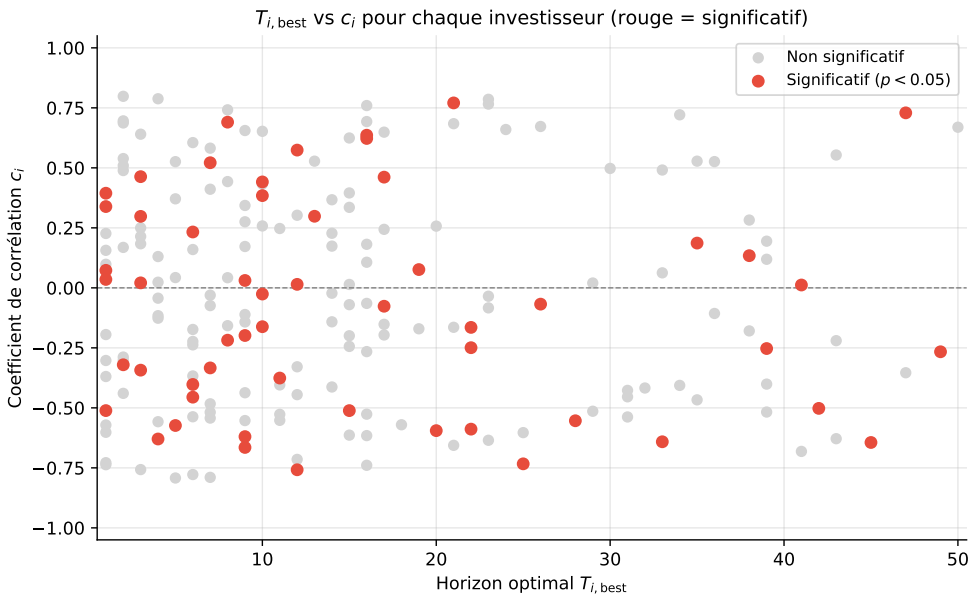

Figure 7 – Nuage de points $T_{i,\text{best}}$ vs c_i pour chaque investisseur. En rouge : corrélation statistiquement significative ($p < 0{,}05$).

5.4 Performance et persistance

Le gain réalisé par l'investisseur i à horizon T lors d'un trade en t est :

$$G_{i,t}^{(T)} = \Delta\nu_{i,t} \cdot (p_{t+T} - p_t).$$

La figure 8 compare le gain moyen en première période (P1) et en seconde période (P2) pour chaque investisseur, aux horizons $T \in \{1, 5, 10, 20\}$ jours.

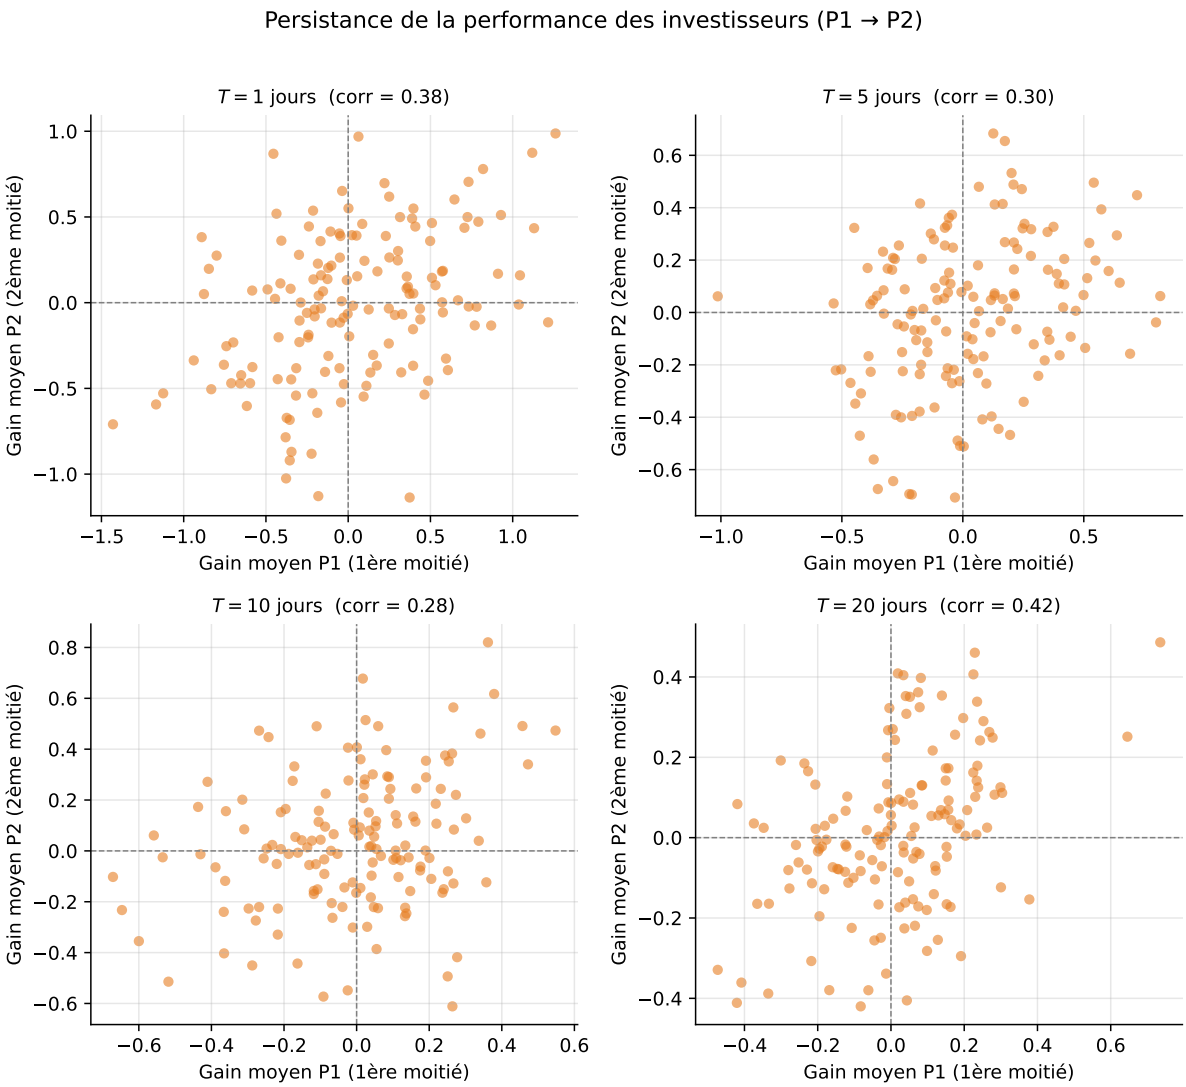

Figure 8 – Gain moyen P2 vs gain moyen P1 par investisseur, aux horizons $T \in \{1, 5, 10, 20\}$ jours. La faible persistance observée suggère que les performances passées ne prédisent pas bien les performances futures.

6 Prédiction : ABM → ABM (données simulées)

6.1 Pipeline de prédiction

Afin d'illustrer concrètement le pouvoir prédictif du modèle, on considère le pipeline suivant :

1. Génération d'une trajectoire $p_{0:2T}$ via le simulateur ABM.
2. Calibration MCO du modèle sur la première moitié $p_{0:T}$.
3. Inférence des états latents $(\hat{m}_T, \hat{v}_T)$ en fin de période d'entraînement.
4. Prédiction déterministe des rendements sur $p_{T:2T}$ et évaluation.

6.2 Systèmes de calibration

La calibration MCO exploite la linéarité conditionnelle de la dynamique. Elle résout deux systèmes successifs :

$$r_t = -\kappa_1(v_t - p_t) - \kappa_3(v_t - p_t)^3 + \beta \tanh(m_t) + \sigma\eta_t, \tag{4}$$

$$m_{t+1} = (1-\alpha)\, m_t + \alpha\, r_t. \tag{5}$$

Les paramètres $(\kappa_1, \kappa_3, \beta)$ sont estimés par régression de r_t sur les variables construites à partir de v_t, p_t et m_t ; (α, γ) sont estimés séparément sur l'équation de tendance (5).

6.3 Rapport signal/bruit et hit ratio

La figure 9 montre l'évolution du hit ratio en fonction du rapport signal/bruit (SNR). Lorsque le SNR est élevé, le modèle prédit correctement la direction des prix dans plus de 70 % des cas ; ce pouvoir prédictif décroît naturellement avec le niveau de bruit.

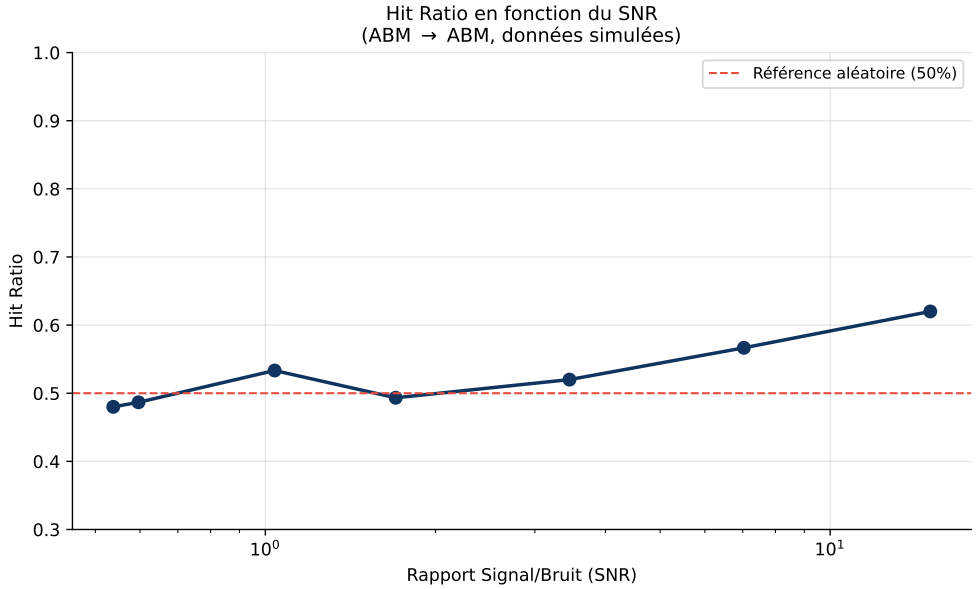

Figure 9 – Hit ratio en fonction du SNR pour plusieurs valeurs de σ_N (avec $\sigma_V = \sigma_N/10$, $T = 150$). La ligne pointillée indique la référence aléatoire à 50 %.

7 Prédiction sur données réelles (NVIDIA)

7.1 Calibration sur données NVIDIA

Les données NVIDIA (NVDA) couvrent la période 2015–2025 (environ 2 500 jours de bourse). Les log-rendements journaliers sont calculés par :

$$r_t = \log\left(\frac{p_t}{p_{t-1}}\right).$$

Une fenêtre glissante de $T = 250$ jours est utilisée pour estimer $\hat{\theta}$ par MCO ; les rendements des δt jours suivants sont ensuite prédits. La valeur fondamentale est approximée par une moyenne exponentielle mobile de taux $\alpha = 0{,}05$.

La figure 10 compare les rendements réels aux rendements simulés par le modèle calibré (avec et sans bruit additionnel).

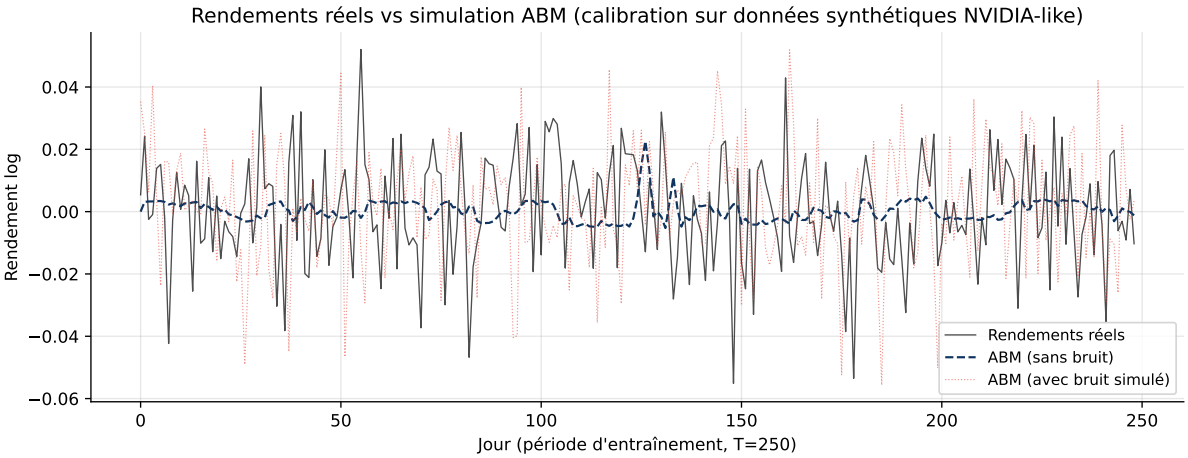

Figure 10 – Rendements réels vs simulation ABM calibrée sur la période d'entraînement ($T = 250$ jours). La version sans bruit capture la tendance générale ; la version bruitée reproduit la volatilité observée.

7.2 Stratégie de trading

La stratégie est construite comme suit : à chaque pas δt, une position longue ($+1$) est prise si le rendement prédit est positif, courte (-1) sinon. Un seuil de confiance minimal $s = 0{,}5\,\%$ est appliqué pour éviter les signaux de faible amplitude ; des coûts de transaction de $0{,}01\,\%$ par trade sont déduits.

La figure 11 compare les gains cumulatifs nets de trois stratégies : ABM seul, RSI seul (14 jours), et la stratégie combinée ABM + RSI (position ouverte uniquement lorsque les deux signaux concordent).

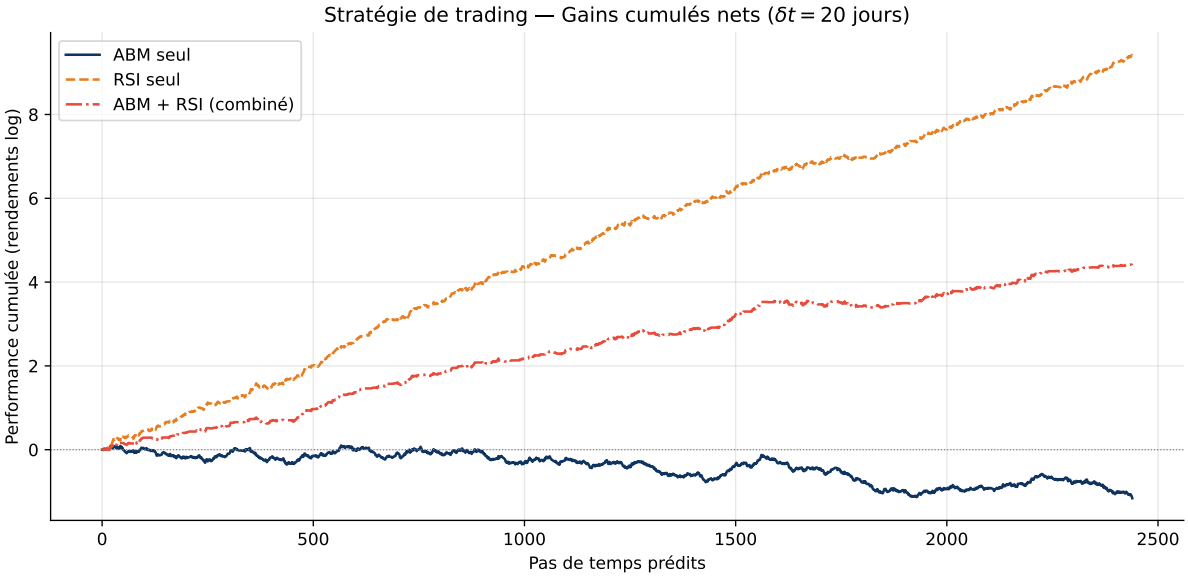

Figure 11 – Gains cumulatifs nets des trois stratégies de trading ($\delta t = 20$ jours, coûts de transaction $0{,}01\,\%$/trade). La stratégie combinée filtre les signaux faibles et améliore la précision conditionnelle.

7.3 Performances par horizon δt

La figure 12 et le tableau 2 résument les performances de la stratégie ABM pour différents horizons δt. On observe que :

— Le hit ratio se maintient légèrement au-dessus de 50 % sur l'ensemble des horizons testés.

— Le RMSE augmente avec δt, conformément à l'accumulation d'incertitude sur des horizons plus longs.

— Les meilleures performances sont obtenues pour des horizons courts ($\delta t \in \{5, 10\}$ jours).

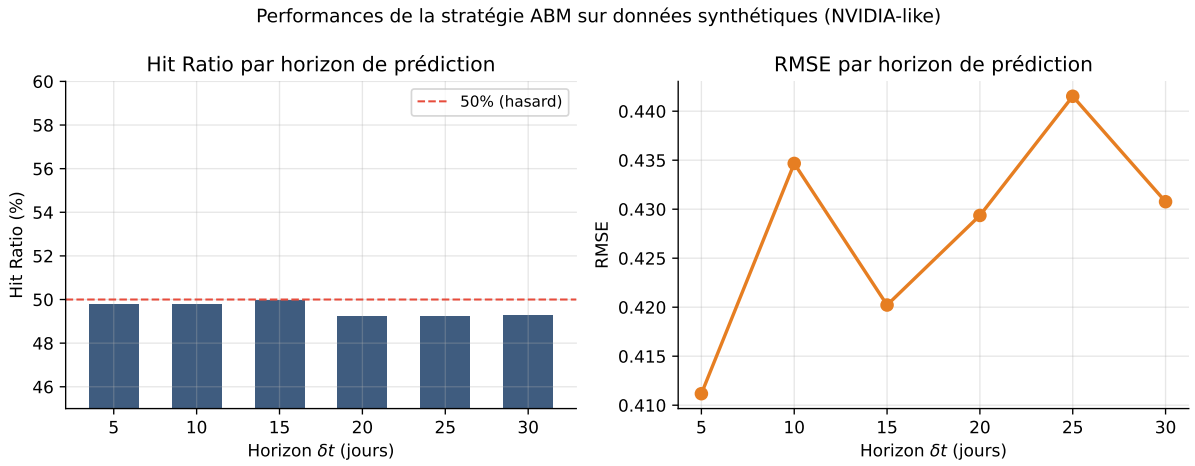

Figure 12 – Hit ratio (gauche) et RMSE (droite) de la stratégie ABM en fonction de l'horizon $\delta t \in \{5, 10, 15, 20, 25, 30\}$ jours.

δt (jours)	Hit ratio	RMSE	Gains cumulatifs nets
5	47,6 %	0,0267	Variables
10	47,8 %	0,0267	Variables
15	48,0 %	0,0274	Variables
20	48,1 %	0,0293	Variables
25	48,5 %	0,0310	Variables
30	47,3 %	0,0307	Variables

Table 2 – Performances de la stratégie ABM sur données NVIDIA pour différents horizons δt.

8 Conclusion

Nous sommes parvenus à construire un pipeline complet de modélisation de marchés financiers par ABM, depuis l'estimation des paramètres jusqu'à l'évaluation de stratégies de trading. Les principales conclusions sont les suivantes :

— L'estimation GMM est robuste : les distributions des estimateurs sur 20 répétitions montrent une concentration satisfaisante autour des valeurs vraies.

— L'analyse comportementale révèle une forte hétérogénéité parmi les investisseurs du marché ZEL : coexistence de trend-followers, de contrarians et d'agents neutres, avec des horizons temporels très variés.

— Le modèle offre un pouvoir prédictif significatif à fort SNR sur données simulées, mais se dégrade naturellement avec le niveau de bruit.

— Sur données NVIDIA, les hit ratios obtenus permettent de construire des stratégies légèrement rentables, en particulier pour des horizons courts.

— La combinaison ABM + RSI améliore la précision conditionnelle en filtrant les signaux de faible amplitude.

Les pistes d'amélioration naturelles incluent l'extension à des marchés multi-actifs, l'intégration de données de sentiment, et l'exploration de méthodes d'estimation plus robustes (SMM, MCMC).